고객 이탈(Churn) 예측
논문 5편 및 GitHub 5개 종합 요약

작성일: 2026-03-31
대상: 논문 5편(PDF) + GitHub 저장소 5개

본 문서는 고객 이탈 예측 관련 학술 논문 5편과 GitHub 저장소 5개를
분석하여 피처, 모델, 하이퍼파라미터, 결과를 상세히 정리한 종합 보고서입니다.

제1부: 논문 상세 요약

[논문 1] The Prediction of Membership Churn in a Large Gym Club Chain

저자: Mayra van der Zanden | 기관: Tilburg University (네덜란드) | 석사 논문, 2023.12

분야: 피트니스(헬스장) 회원 이탈 예측

1. 연구 배경 및 목적

전 세계적으로 헬스장 회원의 50%가 1년 내에 멤버십을 해지한다(MacIntosh & Law, 2015). 이는 비즈니스 손실일 뿐 아니라, 운동 중단으로 인한 공중 보건 문제이기도 하다. 신체 활동 부족은 전 세계 사망률의 6%를 차지하는 4번째 위험 요인이다(WHO, 2019). 본 논문은 대형 헬스장 체인 "GymClubX"의 실제 데이터를 활용하여 머신러닝으로 1년 내 회원 이탈을 예측하고, 이탈 위험 회원에 대한 유지 전략을 수립하는 것이 목표이다.

부가 연구 질문: (1) 여러 지점 분산 이용(distributed network)이 이탈에 미치는 영향은? (2) XGBoost가 LR 대비 얼마나 우수한가?

2. 데이터 상세

CM.com이 제공한 실제 대형 헬스장 체인 데이터. 비공개, 익명화 처리됨.

2-1. 원시 데이터 구조

3개의 원시 테이블로 구성: (1) 사용자 데이터(user data), (2) 멤버십 데이터(membership data), (3) 방문 데이터(visit data). 이를 병합하여 최종 분석 데이터셋 구축.

2-2. 기초 통계

변수	유형	값/분포	설명
Churn (타겟)	이진	Yes 36% / No 44%	1년 내 멤버십 해지 여부
Gender	범주	남 60% / 여 40%	성별
Age	연속	평균 31.2세 (SD 11.4)	13~90세 범위
Country	범주	프랑스54%/네덜란드21%/벨기에17%/스페인6.6%/룩셈1.3%/독일0.1%	회원 국가
Membership Type	범주	Basic 10.7% / Comfort 48% / Premium 41.3%	멤버십 등급
Start Month	범주	평균 5.9 (SD 3.4)	가입 월 (1~12)
Duration (days)	연속	평균 436.3일 (SD 333.3)	멤버십 기간. 35~11,535일
Visit Frequency	연속	평균 16.8회 (SD 26.7)	연간 방문 횟수. 0~487회
Club Count	연속	평균 1.4 (SD 1.3)	이용 클럽 수. 0~73개
Country Count	연속	평균 0.8 (SD 0.4)	이용 국가 수. 0~5개
>1 Club	이진	Yes 30.5% / No 69.5%	2개 이상 클럽 이용 여부
International	이진	Yes 1.2% / No 98.8%	해외 클럽 이용 여부

2-3. 사분위 범주화

연속형 변수(Age, Duration, Visit Frequency)를 사분위수(25th, 50th, 75th percentile)로 4구간으로 범주화하였다:

- Age: Q1(13~22) / Q2(22~27) / Q3(27~36) / Q4(36~90)
- Duration: Q1(35~203일) / Q2(203~392일) / Q3(392~519일) / Q4(519~11,535일)
- Visit Frequency: Q1(0~2회) / Q2(2~9회) / Q3(9~31회) / Q4(31~487회)
- Start Month도 분기별로 범주화: Q1(1~3월) / Q2(3~6월) / Q3(6~9월) / Q4(9~12월)

3. 전처리 상세

3-1. 다중공선성 검사

상관행렬(Correlation Matrix)과 VIF(분산팽창인자) 두 가지로 검사:

- 상관행렬: 같은 변수의 사분위 간 높은 상관 확인 (특히 Membership Type). 그러나 VIF 점수가 모두 10 미만이므로 허용 범위(Vittinghoff et al., 2006).
- 개별 변수 VIF: Membership Type 5.30, Age 8.27, Duration 3.45, Start Month 2.93, Gender 2.56, Visit Count 1.86, >1Club 1.78, International 1.04, Country 1.00
- 사분위 변수 VIF: 최대값 membershipType_2 = 9.98, startMonth_2 = 9.68, duration_3 = 8.06 등. 모두 10 미만.

모든 변수와 사분위를 유지하기로 결정 (정보 보존 및 해석력 유지 목적).

4. 모델 상세

4-1. Logistic Regression (기준 모델)

이진 분류를 위한 통계 모델. 입력 변수의 선형 결합을 시그모이드 함수에 통과시켜 이탈 확률(0~1) 출력.

- 하이퍼파라미터 그리드서치:
  * C (정규화 강도): [0.001, 0.01, 0.1, 1, 10, 100]
  * penalty: [l2, none]
  * solver: [lbfgs, sag]
- 최적 설정: C=1, penalty=l2, solver=lbfgs
- 해석 도구: 회귀계수(B), p-value, 표준오차, Wald 통계량
  * 양의 계수 = 이탈 확률 증가, 음의 계수 = 이탈 확률 감소

4-2. XGBoost

Extreme Gradient Boosting. 결정 트리를 순차적으로 구축하며 이전 트리의 오류를 보정하는 앙상블 기법.

- 하이퍼파라미터 그리드서치:
  * learning_rate: [0.01, 0.1, 0.2, 0.3]
  * max_depth: [3, 4, 5, 6, 7, 8]
  * n_estimators: [50, 100, 150, 200, 250]
- 해석 도구: Feature Importance Plot (트리 분할에서 변수의 사용 빈도/유용성)
- SHAP (SHapley Additive exPlanations): 각 변수가 개별 예측에 미치는 영향의 방향과 크기. 빨간 점=이탈, 파란 점=유지. 0선 기준 오른쪽=이탈 확률 증가.

5. 결과 상세

모델	F1-score	Precision	Recall	Accuracy	AUC
LR	0.638	0.718	0.575	0.763	0.798
XGBoost	0.775	0.871	0.698	0.853	0.913

5-1. LR 피처별 영향력 (회귀계수 분석)

- Visit Frequency Q1(0~2회): 양의 계수, 높은 Wald -> 이탈 확률 크게 증가
- Visit Frequency Q4(31회+): 음의 계수 -> 이탈 확률 감소
- Duration Q2-Q3(203~519일): 양의 계수 -> 이탈 위험
- Duration Q4(519일+): 음의 계수 -> 이탈 감소
- Age Q4(36세+): 음의 계수, 유의미 -> 고연령 이탈 적음
- >1 Club: 음의 약한 계수 -> 다지점 이용 시 이탈 소폭 감소
- International: 양의 약한 계수 -> 해외 이용 시 이탈 소폭 증가

5-2. XGBoost SHAP 분석 (상세)

- Feature Importance 1위: Visit Frequency Q1(0~2회) - 트리 분할에 가장 많이 사용
- 2위: Start Month 9월 (9월 가입자 이탈 위험 높음)
- 3위: Duration Q2(203~392일)
- SHAP 방향성:
  * Visit Freq Q1: 빨간 점이 오른쪽 집중 -> 방문 2회 미만은 이탈 강하게 증가
  * Visit Freq Q4: 파란 점이 왼쪽 -> 방문 31회+ 이탈 강하게 감소
  * Start Month 9,10,11,12월: 이탈 확률 증가 방향

* Duration Q2-Q3(203~519일): 빨간 점 오른쪽 집중 -> 이탈 강하게 증가
* Duration Q4(519일+): 이탈 감소 방향
* >1 Club, International: 둘 다 Feature Importance 최하위, SHAP 영향 매우 미미

6. LR vs XGBoost 비교

- 공통점: 방문 빈도(2회 미만/31회 이상)와 멤버십 기간(203~519일/519일+)이 양쪽 모두 중요
- 차이점: LR은 나이 36세+를 중요하게 봤으나 XGBoost는 낮은 중요도. 반대로 XGBoost는 가입 월(11~12월)을 중요하게 봤으나 LR에서는 영향 작음.
- 해석: LR은 변수 간 선형 관계만 포착, XGBoost는 복잡한 비선형 패턴(시기별 이탈 경향 등)까지 학습

7. 실무 시사점

- 방문 빈도 향상이 핵심: PT, 그룹수업, 반지도 운동. 방문빈도-만족도 선순환(Ferrand 2010)
- 가입 후 7~17개월 회원에게 집중 관리, 9~12월 신규 가입자 특별 관리
- 직원 참여도(employee engagement)가 회원 만족/유지에 큰 영향
- 9개 변수 모두 운영 데이터 -> 추가 수집 없이 즉시 적용 가능
- 한계: 심리적/외부 요인 미반영, 이탈 사유 없음, 해석 형식 차이

[논문 2] Churn Prediction for Gym Members Using ANN + Habit Formation

저자: May Aldosary, Abdalla Alrashdan | 기관: Alfaisal University (사우디)

발표: IEOM 2021 국제학회 (싱가포르) | 분야: 피트니스 이탈 + 심리학

1. 연구 목적

피트니스 분야의 이탈 연구는 심리학적 관점이 주류였으나 머신러닝을 보조 도구로 활용한 연구는 거의 없었다. 본 연구는 심리학의 "습관 형성(Habit Formation)" 개념을 피처 선택의 이론적 근거로 삼고, ANN(인공신경망)으로 이탈을 예측한 최초의 연구 중 하나이다.

2. 데이터 상세

- 출처: 사우디아라비아의 비교적 신생 여성 전용 헬스장 체인
- 규모: 809건
- 기간: 2019.11 ~ 2020.11 (코로나19 영향 포함)
- 코로나19 처리: 2020.3~7월 폐쇄, 멤버십 동결, 무료 온라인 수업 제공. 재개 후 멤버십 해동하지 않은 고객은 이탈/유지 분류 불가하여 분석에서 제외.
- 이탈 정의: 수동 갱신 방식. 만료 후 1개월 내 미갱신 = 이탈(1), 재구독 = 유지(0)
- 예약 시스템: 모바일 앱으로 서비스 예약 -> 도착 시 리셉션/트레이너 체크인

3. 피처 상세 (추출 -> 선택 2단계)

3-1. 1단계: 문헌 기반 추출 (6개 피처)

습관 형성 이론(Oliveira, 2018)에 근거: 헬스장 방문이 습관화되면 장기 유지 가능성 증가.

피처명	유형	설명
Total_Visits	정수(이산)	예약 후 실제 출석한 총 횟수
No_Shows	정수(이산)	예약했으나 미출석한 총 횟수
Cancelled	정수(이산)	예약 후 취소한 총 횟수
Member_Since	정수(이산)	가입 후 경과 개월 수
Membership_Package	명목(텍스트)	패키지: Active, Active+, Athlete 3단계
Membership_Period	순서(정수)	계약 기간: 3개월 또는 6개월
Status (타겟)	이진	1=이탈, 0=유지

샘플 레코드 예시: Client 1 - Visits:47, No_Shows:0, Cancelled:1, Period:3개월, Since:6개월, Athlete, 유지

3-2. 2단계: 통계적 필터링

- Spearman 상관계수 (정량 변수 간):
  * Total_Visits, No_Shows, Cancelled 간 강한 상관 발견
  * Member_Since와 Membership_Period는 서로 약한 상관
- 타겟(Status)과의 상관:
  * Total_Visits: -0.4196 (가장 강한 음의 상관 = 방문 많을수록 이탈 적음)
  * Member_Since: -0.3557
  * No_Shows: (중간 수준)
  * Membership_Period: 0.2684
  * Cancelled: (중간 수준)
  * Membership_Package: 0.1518 (매우 약함)
- Cramer V (명목 변수-타겟 간): Membership_Package와 Status 간 매우 약한 연관
- 최종 결정:
  * Total_Visits/No_Shows/Cancelled 중 타겟 상관 최고인 Total_Visits만 대표 선택
  * Membership_Package 제거 (타겟 상관 0.1518으로 너무 약함)
  * 최종 피처 3개: Total_Visits, Member_Since, Membership_Period

4. ANN 모델 구조 상세

4-1. 고정 파라미터

- 활성화 함수: ReLU (Rectified Linear Unit) - f(x)=max(0,x). ANN 시작점으로 일반적 권장(Geron 2019)
- 손실 함수: Binary Cross Entropy - 이진 분류이므로(Chollet 2017)
- 최적화기: L-BFGS (Broyden-Fletcher-Goldfarb-Shanno) - 소규모 데이터(809건)에 적합(Pedregosa 2011). Adam 대비 소규모에서 더 효율적.

4-2. 실험적 튜닝 파라미터

- 은닉층 수: 1개부터 점진적으로 증가시키며 실험. 1개에서 충분한 성능 확인("An MLP with just one hidden layer can theoretically model even the most complex functions" - Geron 2019). 층 추가 시 성능 차이 없어 1개로 확정.
- 은닉 노드 수: 큰 수(수백)에서 시작하여 점진적으로 감소. 성능 저하 없는 최소값으로 150개 확정.
- 학습률: 작은 값에서 점진적으로 증가. 최적 0.01 확정. 성능에 가장 큰 영향을 미치는 파라미터.

4-3. 최종 네트워크 구조

- 입력층: 3개 노드 (Total_Visits, Member_Since, Membership_Period)
- 은닉층: 1개, 150개 노드, ReLU 활성화
- 출력층: 1개 노드 (이탈 확률)
- 검증: 5-fold 교차 검증 (각 fold에서 Accuracy, Sensitivity, Specificity 측정 후 평균)

5. 결과

지표	값	의미	산출 방법
Accuracy	92.1%	전체 정확도	정확 예측 / 전체
Sensitivity	89.1%	이탈자 정분류율(Recall)	정확 이탈 예측 / 전체 이탈
Specificity	93.8%	유지자 정분류율	정확 유지 예측 / 전체 유지

선행 연구 Semrl & Matei(2017)의 최고 74.6% 대비 17.5%p 향상. 소규모(809건)에서도 습관 형성 기반 체계적 피처 선택이 고성능을 이끌어낸 사례.

6. 핵심 발견

- 필터링 단계에서 출석(Total_Visits)과 이탈 간 음의 상관(-0.4196) 확인: 습관 형성 이론(Oliveira 2018)의 실증적 뒷받침
- 코로나19 팬데믹 중에도 출석-이탈 관계는 유효
- 학습률 0.01이 성능에 가장 큰 영향: ANN 분야 일반 이론과 일치
- 한계: 809건 소규모, 코로나19 비정상 기간 포함, ANN 단일 모델만 사용, 비교 모델 없음

[논문 3] Churn Prediction in OTT for Customer Retention Using ML Algorithms

저자: G. Shabana, M. Jyothi, K. Ali Mahaboob Basha, D. Mounika Reddy, M. Charan Tej

기관: Srinivasa Ramanujan Inst. of Tech. (인도) | ICRDICCT 2025 학회

1. 연구 목적

OTT(Over-The-Top: 넷플릭스, 왓챠 같은 인터넷 기반 스트리밍) 플랫폼의 구독자 이탈을 다양한 ML로 예측. 특히 클래스 불균형 문제를 SMOTE로 해결한 전후 비교에 초점. 이탈 원인: 경쟁 플랫폼, 불만족 고객 서비스, 기능 부재, 가격.

2. 데이터 상세

2,000건, 16개 속성 + 타겟(churn: 0/1)

피처명	유형	설명	전처리
Year	정수	구독 연도	제거 (불필요)
customer_id	정수	고객 고유 ID	제거 (불필요)
phone_no	문자열	전화번호	제거 (불필요)
Gender	범주	성별	결측: 최빈값 대체, 더미변환
Age	정수	나이	유지
multi_screen	이진	다중 기기 구독 여부	더미변환
no_of_days_subscribed	정수	구독 일수	유지
mail_subscribed	이진	메일 구독 여부	더미변환
weekly_mins_watched	실수	주간 시청 분	유지
maximum_daily_mins	실수	최대 일일 시청 분	유지
minimum_daily_mins	실수	최소 일일 시청 분	상관 높음 주의
weekly_max_night_mins	실수	주간 야간 시청 분	유지
videos_watched	정수	총 시청 영상 수	유지
maximum_days_inactive	실수	최대 비활성 일수	결측: 중앙값 대체
customer_support_calls	정수	고객 지원 전화 횟수	유지
churn (타겟)	이진	0=유지, 1=이탈	결측: 최빈값 대체

3. 전처리 상세

- 불필요 피처 제거: customer_id, year, phone_no (식별용, 예측에 무관)
- 결측치: gender(최빈값), maximum_days_inactive(중앙값), churn(최빈값)
- 이상치 탐지: 수행 결과 이상치 없음
- 상관분석: maximum_days_inactive와 minimum_daily_min 간 높은 상관 확인
- 범주형 -> 이진 더미변환: gender, multi_screen, mail_subscribed

- 데이터 분할: 학습 60% / 테스트 40%, random_state=78

4. 사용 모델 상세

4-1. Decision Tree (2가지 버전)

- Entropy 기반 (ID3): 정보 이득(Information Gain)으로 분할 기준 결정
- Gini 기반 (CART): 지니 불순도(Gini Impurity)로 분할 기준 결정

4-2. Random Forest

- 다수 결정트리의 앙상블. 랜덤 부분집합으로 각 트리 훈련, 다수결 투표로 최종 예측

4-3. Gradient Boosting

- 약한 학습기를 순차 결합. 이전 모델의 잔차를 다음 모델이 학습.

4-4. XG Boost

- Gradient Boosting의 최적화 버전. 정규화(regularization) 내장으로 과적합 방지. 병렬 처리로 속도 향상.

5. 결과 상세

5-1. SMOTE 전

모델	Accuracy	F1-Score	Recall	Precision
Random Forest	0.912	0.602	0.486	0.791
Decision Tree ID3	0.911	0.590	0.468	0.797
XG Boost	0.911	0.603	0.495	0.771
Decision Tree CART	0.906	0.540	0.404	0.815
Gradient Boosting	0.873	0.346	0.248	0.574

문제: Accuracy 87~91%로 높아 보이나, Recall(이탈자 탐지율)이 0.25~0.50으로 매우 낮음. 이탈자의 절반 이상을 놓치고 있다는 뜻. 이는 이탈 클래스가 소수인 불균형 데이터의 전형적 증상.

5-2. SMOTE 적용

SMOTE(Synthetic Minority Over-sampling Technique): 소수 클래스(이탈)의 기존 샘플들 사이의 합성 데이터를 생성하여 클래스 비율을 맞추는 오버샘플링 기법.

5-3. SMOTE 후

모델	Accuracy	F1-Score	Recall	Precision
XG Boost (SMOTE)	0.909	0.644	0.606	0.688
DT ID3 (SMOTE)	0.897	0.643	0.679	0.612
Random Forest (SMOTE)	0.897	0.627	0.633	0.622
DT CART (SMOTE)	0.890	0.614	0.642	0.588
Gradient Boost (SMOTE)	0.871	0.502	0.477	0.531

5-4. SMOTE 전후 변화 분석

- F1-Score: RF 0.602->0.627(+0.025), XGBoost 0.603->0.644(+0.041), GB 0.346->0.502(+0.156)
- Recall: RF 0.486->0.633(+0.147), XGBoost 0.495->0.606(+0.111), GB 0.248->0.477(+0.229)
- Accuracy: 소폭 하락 (RF 0.912->0.897 등). 이는 유지자 일부를 이탈로 잘못 분류하기 때문이나, 비즈니스적으로는 이탈자를 놓치지 않는 것이 더 중요.
- XG Boost가 SMOTE 전후 모두 최고 성능
- SMOTE 전 최고 Accuracy: RF(0.912), SMOTE 후 최고: XGBoost(0.909)

[논문 4] OTT Subscriber Churn Prediction Using Machine Learning

저자: Needhi Devan Senthil Kumar | 기관: CSUSB (미국) | 석사 프로젝트, 2023.5

1. 연구 질문

- Q1: 구독자 이탈 극복에 어떤 ML 알고리즘이 사용되는가?
- Q2: ML로 OTT 플랫폼의 구독자 이탈을 어떻게 예측하는가?
- Q3: 구독자를 어떻게 유지하고 타겟팅을 개선하는가?

2. 데이터 상세

Kaggle 저장소에서 수집. 2,000건, 16개 열. 논문3과 동일한 Kaggle 데이터셋으로 추정됨.

S.No	피처명	설명
1	Year	구독 연도
2	customer_id	구독자 ID
3	phone_no	전화번호
4	Gender	성별
5	Age	나이
6	no_of_days_subscribed	구독 후 경과 일수
7	multi_screen	단일/다중 화면 구독
8	mail_subscribed	메일 수신 여부
9	weekly_mins_watched	주간 시청 분
10	minimum_daily_mins	최소 일일 시청 분
11	maximum_daily_mins	최대 일일 시청 분
12	weekly_max_night_mins	야간 시청 분
13	videos_watched	총 시청 영상 수
14	maximum_days_inactive	최대 비활성 일수
15	customer_support_calls	고객 지원 전화 수
16	Churn	1=이탈, 0=유지

3. 알고리즘 5가지 + 하이퍼파라미터

3-1. Logistic Regression

- sklearn.linear_model.LogisticRegression
- 기본 하이퍼파라미터 사용

3-2. Multi-Layer Perceptron

- sklearn.neural_network.MLPClassifier
- hidden_layer_sizes=(100,), activation="relu", solver="adam", alpha=0.0001, max_iter=1000

3-3. Random Forest

- sklearn.ensemble.RandomForestClassifier
- 기본 하이퍼파라미터 사용

3-4. Decision Tree

- sklearn.tree.DecisionTreeClassifier
- 기본 하이퍼파라미터 사용

3-5. Gradient Boosting Machine

- sklearn.ensemble.GradientBoostingClassifier
- 기본 하이퍼파라미터 사용

4. 결과

모델	Accuracy	AUROC	비고
Logistic Regression	86.50%	0.539	AUROC 0.5에 가까움 = 랜덤 수준
Multi-Layer Perceptron	87.50%	0.552	
Random Forest	91.00%	0.676	
Decision Tree	92.25%	0.779	
Gradient Boosting Machine	93.25%	0.793	최고 성능

GBM > DT > RF > MLP > LR 순서. 특히 LR의 AUROC 0.539는 랜덤 추측(0.5)에 가까워 실질적 분류 능력이 매우 낮음을 의미. GBM이 Accuracy 93.25%, AUROC 0.793으로 가장 우수.

AUROC 해석: 0.5=랜덤, 0.7~0.8=양호, 0.8~0.9=우수, 0.9~1.0=탁월

5. 구독자 유지 전략 (Q3)

- 이탈 위험 구독자 조기 식별: 모델로 고위험 구독자 목록 생성
- 개인화 프로모션: 할인 구독, 무료 체험 연장, 독점 콘텐츠
- 고객 서비스 개선: 대기 시간 단축, 불만 즉시 해소
- 로열티 프로그램: 장기 구독자에게 독점 혜택
- 가격 전략: 구독 이력/행동 기반 최적화
- 향후: 비정형 데이터(SNS, 리뷰), CNN/RNN 딥러닝, 실시간 클릭스트림

[논문 5] Improving Customer Churn Prediction for OTT Platforms with ML

저자: B. Prasanna Kumar, E. Sreenivasa Reddy | IJBAS 14(4), 2025

분야: OTT 이탈 예측 (고급 프레임워크) - 5편 중 가장 방법론적으로 진보된 연구

1. 핵심 기여 3가지

1-1. 부분 이탈(Partial Churn) 개념

기존: 완전 해지만을 이탈로 정의. 본 논문: 완전 해지 전의 경고 신호도 "부분 이탈"로 포착. 예시:

- 시청 빈도 급감 (매일 -> 주 1회)
- 프리미엄에서 베이직으로 다운그레이드
- 멀티플랫폼 분산 이용 (넷플릭스+디즈니+ 병행)

이를 통해 완전 이탈 전 사전 개입(맞춤 프로모션, 콘텐츠 추천) 가능.

1-2. Serial Miss Forest Imputation (결측치 처리)

알고리즘 과정:

- 1단계: 결측값을 평균으로 초기 대체
- 2단계: 변수를 결측 수 기준 오름차순 정렬
- 3단계: 각 변수에 대해 관측된 데이터로 RF 훈련 -> 결측값 예측
- 4단계: 수렴할 때까지 반복 (새 대체값과 이전 대체값의 차이가 증가하면 중단)

4가지 방법 비교 결과:

- Mean Imputation: 중앙값 ~0, 분산 매우 큼(-15~+15), 극단값 다수
- Median Imputation: 중앙값 ~4, 분산 약간 감소
- KNN Imputation: 중앙값 ~3.5, 더 균형적이나 여전히 변동
- Serial Miss Forest: 중앙값 ~5, IQR 0~8, 극단값 최소 -> 가장 안정적이고 정확

1-3. DCRRF (Dynamic Correlated Regularized Random Forest) 피처 선택

기존 Random Forest + 상관 기반 선택(CFS)을 결합한 하이브리드 기법:

- 각 트리마다 부트스트랩 샘플에서 상관행렬 계산
- CFS 기준으로 동적 피처 부분집합 선택: 타겟과 상관 높고 + 피처 간 상관 낮은 조합
- 정규화된 목적함수로 트리 훈련: Impurity + lambda * Complexity
- 최종 최적 피처 = 모든 트리 선택의 교집합
- 예시: "평균 시청 시간", "비활성 일수", "최근 시청 분"이 상관 높으면 -> 가장 유의미한 것 하나만 유지

2. 데이터

Kaggle "OTT Churn Prediction" 데이터셋, 2,000건, 16 속성. 80/20 분할.

결측 데이터 현황: Average.Watch.Time.mins가 가장 많은 결측, 이어서 Competitor.Content, Viewer.Gender 순.

3. DCRRF 피처 중요도 결과

- 1위: Shares (공유 횟수) - importance 0.0648
- 공유 빈번 = 참여도 높음 = 이탈 적음
- 2위 이하: 비활성 일수, 평균 시청 시간 등

실무 해석: 콘텐츠 공유를 장려하는 것이 가장 효과적인 유지 전략. 비활성 감지, 시청 시간 모니터링도 중요.

4. 사용 모델 및 결과

4-1. 모델 3가지

- Logistic Regression: 기준 모델
- Random Forest: 앙상블
- XGBoost: 목적함수 = loss(y, y_hat) + Omega(f). Omega는 정규화 항으로 과적합 방지. 최종 예측 = 모든 트리 예측의 합.

4-2. 결과

모델	Accuracy	Precision	Recall	F1-Score
Logistic Regression	87%	0.87	0.87	0.87
Random Forest	92%	0.92	0.92	0.92
XGBoost	96%	0.96	0.96	0.96

- 전체 프레임워크(Miss Forest + DCRRF + XGBoost): 98% 정확도
- 10-fold 교차 검증: 평균 96.8% +/- 1.2% (과적합 아님 확인)
- 다른 도메인(통신 이탈) 적용: 92% (OTT 피처 구조와 다름에도 유효)
- 피처 선택(DCRRF)이 과적합 방지에 기여: 중복/노이즈 예측 변수 제거

5. 이탈 유형 분류 (본 논문의 이론적 기여)

- 자발적(Voluntary) 이탈: 서비스 불만, 경쟁사 전환 등 의식적 해지
- 비자발적(Involuntary) 이탈: 결제 실패, 기술 문제 등 의도치 않은 해지
- 기본 이탈률 = 이탈 고객 수 / 전체 고객 수
- 심리학적 관점: 콘텐츠 피로감(content fatigue), 낮은 감정적 애착
- 경제학적 관점: 가격 민감도, 계약 유연성(언제든 해지 가능), 구독 피로감(subscription fatigue)

제2부: GitHub 저장소 상세 요약

[GitHub 1] Fitness-Center-Retention-Analysis

https://github.com/bhutto17/Fitness-Center-Retention-Analysis

- 도메인: 피트니스 센터 고객 유지
- 기법: EDA(탐색적 데이터 분석) + Gradient Boosting
- 성능: Accuracy 92.5%, AUC 97.25%
- 추가: K-means 클러스터링으로 고객 세분화
- 특징: 이탈 예측 + 세그먼테이션 결합. 세분화된 그룹별 차별 전략 수립 가능.
- 프로젝트 적용 참고: 피트니스 도메인에 가장 직접적으로 참고 가능한 구현체

[GitHub 2] Churn-Prediction-Credit-Card

https://github.com/allmeidaapedro/Churn-Prediction-Credit-Card

- 도메인: 은행 신용카드 이탈
- 최고 모델: LightGBM (Gradient Boosting 경량화 버전)
- 특징: 체계적 전처리 파이프라인, 다수 모델 비교
- 프로젝트 적용 참고: LightGBM 구현 방법, 금융 도메인 피처 엔지니어링

[GitHub 3] customer_churn_segmentation

https://github.com/biancaportela/customer_churn_segmentation

- 모델: LR, DT, RF 등 다수 + 클러스터링(세그먼테이션)
- 특징: 이탈 예측 + 고객 분류를 하나의 파이프라인으로 통합
- 프로젝트 적용 참고: 예측과 세분화를 결합하는 방법론

[GitHub 4] Credit-Card-Users-Churn-Prediction

https://github.com/dardenkyle/Credit-Card-Users-Churn-Prediction

- 특징: 철저한 EDA + Feature Engineering + 다양한 샘플링 기법
- 클래스 불균형 처리를 위한 여러 샘플링 전략 비교가 핵심
- 프로젝트 적용 참고: 피처 엔지니어링 방법, 불균형 처리 전략 비교

[GitHub 5] Customer_Churn_Prediction_Using_PySpark

https://github.com/evelyncy96/Customer_Churn_Prediction_Using_PySpark

- 빅데이터 기반 실시간 이탈 예측 파이프라인
- 기술 스택:
  * Amazon S3: 대용량 데이터 저장
  * Databricks: 데이터 처리/분석 플랫폼
  * Spark MLlib: 분산 머신러닝 라이브러리
  * Amazon QuickSight: 대시보드/시각화
- 프로젝트 적용 참고: 프로덕션급 배포 아키텍처

제3부: 논문 간 비교 분석

1. 도메인별 분류

도메인	해당 자료	데이터 규모	핵심 특성
피트니스	논문1, 논문2, GitHub1	809~수만건	방문 빈도가 핵심
OTT	논문3, 논문4, 논문5	2,000건	시청 행동이 핵심
금융	GitHub2~4	다양	거래/결제 패턴
빅데이터	GitHub5	대규모	분산 처리 아키텍처

2. 피처(변수) 비교: 논문별 사용 피처 총정리

피처 카테고리	논문1(헬스장)	논문2(헬스장)	논문3/4(OTT)	논문5(OTT)
방문/시청 빈도	Visit Frequency	Total_Visits	weekly_mins_watched, videos_watched	Avg Watch Time
비활성/미출석	-	No_Shows(제거)	max_days_inactive	Inactive Days
가입/구독 기간	Duration(days)	Member_Since	no_of_days_subscribed	Subscription Length
멤버십/패키지	Membership Type	Package(제거)	multi_screen, mail_subscribed	-
인구통계	Gender, Age, Country	-	Gender, Age	Gender, Age
고객 행동	>1Club, International	Cancelled(제거)	customer_support_calls	Shares
시간 패턴	Start Month	-	max_night_mins, min/max_daily_mins	-
타겟 정의	1년 내 해지	만료후 1개월 미갱신	Churn 0/1	Churn + 부분이탈

3. 모델 성능 종합 비교

논문	최고 모델	Accuracy	F1-Score	AUC/AUROC	데이터 규모
1	XGBoost	85.3%	0.775	0.913	대형 체인 실데이터
2	ANN(MLP)	92.1%	-	-	809건
3	XGBoost+SMOTE	90.9%	0.644	-	2,000건
4	GBM	93.25%	-	0.793	2,000건
5	XGBoost+FW	98%(CV96.8)	0.96	-	2,000건

XGBoost/Gradient Boosting 계열이 5편 모두에서 최상위. 논문5는 고급 전처리(Miss Forest)+피처선택(DCRRF)으로 98% 달성. 논문1은 실제 기업 데이터로 현실적인 성능(85%) 보고.

4. 핵심 피처 요약

[피트니스 도메인 공통]

- 1순위: 방문 빈도 - 방문 2회 미만이면 이탈 급증, 31회 이상이면 이탈 급감
- 2순위: 멤버십/가입 기간 - 7~17개월이 고위험기, 장기 회원은 안정
- 3순위: 가입 시점 - 9~12월 가입자 이탈 높음

[OTT 도메인 공통]

- 1순위: 시청 시간/영상 수 - 감소 추세가 이탈의 선행 지표
- 2순위: 비활성 일수 - 장기 미접속이 이탈 직결
- 3순위: 콘텐츠 공유 횟수(논문5) - 참여도의 강력한 지표
- 기타: 고객 지원 전화 수, 구독 기간, 야간 시청 패턴

5. 전처리/피처선택 기법 비교

논문	결측치 처리	불균형 처리	피처 선택	피처 변환
1	명시 없음	없음	VIF 검사, 전체 유지	사분위 범주화
2	제외(코로나)	없음	Spearman+Cramer V 필터링	없음
3	최빈/중앙값	SMOTE	상관분석	더미변환
4	명시 없음	없음	문헌 기반	없음
5	Serial Miss Forest	없음(DCRRF 보완)	DCRRF 하이브리드	표준화+정규화

제4부: 프로젝트 적용 종합 시사점

1. 모델 선택 가이드

- 1순위: XGBoost / Gradient Boosting - 5편 모두 최상위. 구조화 데이터 최적. 하이퍼파라미터: learning_rate(0.01~0.3), max_depth(3~8), n_estimators(50~250) 범위에서 그리드서치.
- 2순위: Random Forest - 안정적, 과적합에 강함. 빠른 프로토타입에 적합.
- 기준 모델: Logistic Regression - 필수 포함. 해석력 최고. 오즈비로 변수별 영향 직접 설명 가능.
- ANN(MLP): 데이터 수천건+, 비선형 복잡할 때. 은닉층 1개(150 노드), 학습률 0.01 시작 권장(논문2).

2. 전처리 파이프라인 권장

- 결측치: Serial Miss Forest Imputation 최선(논문5). 차선: KNN Imputation.
- 불균형: SMOTE 적용(논문3에서 F1 +0.04, Recall +0.11 개선 확인).
- 피처 선택: (1) 상관분석으로 중복 제거(상관 0.7+ 시 하나만 유지), (2) DCRRF 또는 SHAP 기반 중요도 분석.
- 피처 변환: 연속형 -> 사분위 범주화(논문1), 범주형 -> 더미변환(논문3), 표준화/정규화(논문5).

3. 피처 설계 가이드 (도메인별)

[피트니스/구독 서비스 권장 피처]

- 방문 빈도(최우선): 주간/월간 방문 횟수, 사분위 범주화(2회 미만/2~9/9~31/31+)
- 가입 기간: 경과 일수, 사분위 범주화(특히 203~519일 고위험기 식별)
- 가입 시점: 월별, 특히 9~12월 플래그
- 예약 행동: 총 예약, 미출석(No_Show), 취소 횟수
- 멤버십 유형: Basic/Comfort/Premium 등급
- 인구통계: 성별, 나이(사분위), 지역

[OTT/스트리밍 권장 피처]

- 시청 행동(최우선): 주간 시청 분, 일일 최대/최소 시청 분, 야간 시청 분, 시청 영상 수
- 비활성: 최대 비활성 일수
- 참여도: 콘텐츠 공유 횟수(논문5에서 1순위), 평점/리뷰 활동
- 구독 정보: 구독 일수, 다중 기기 여부, 메일 수신 여부
- 고객 지원: 지원 전화 횟수
- 인구통계: 성별, 나이

4. 평가 지표

- Accuracy만 불충분(불균형 시 왜곡). 논문3에서 Acc 91%인데 Recall 48%인 사례.
- F1-Score: Precision과 Recall의 조화 평균. 불균형 데이터 주 지표로 권장(논문1).
- AUC-ROC: 임계값 독립적 종합 지표. 모델 비교에 가장 공정(논문4).
- Recall: 이탈 놓치는 비용이 클 때 중시. Precision: 프로모션 비용이 클 때 중시.

5. 도메인별 비즈니스 전략

[피트니스]

- 방문 빈도 2회 미만 회원: 즉각 개입(PT 무료 체험, 그룹수업 초대)
- 가입 후 7~17개월: 집중 관리(만족도 설문, 맞춤 운동 프로그램)
- 9~12월 신규 가입자: 신년 결심 효과 대비 초기 3개월 밀착 관리
- 방문빈도-만족도 선순환 활용: 직원 참여도 높이기

[OTT]

- 비활성 일수 증가: 자동 알림 + 맞춤 콘텐츠 추천
- 공유 행동 장려: 공유 보상 프로그램, 소셜 기능 강화
- 부분 이탈 감지: 시청 감소/다운그레이드 시 사전 개입
- 가격/구독 유연성: 맞춤형 플랜, 로열티 프로그램

6. 배포 아키텍처

- 소규모: scikit-learn + Jupyter -> Flask/FastAPI API화 (GitHub 1~4)
- 대규모: S3 + Databricks + Spark MLlib + QuickSight (GitHub 5)
- 세분화: 이탈 예측 + K-means 클러스터링 결합 (GitHub 1, 3)
- 모니터링: 모델 드리프트 감지, 정기 재학습, A/B 테스트